

1.4. Riscos ètics, socials i legals

M5071 - Models d'Intel·ligència Artificial
Miquel Floriach - mfloriach@sapalomera.cat



Índex

- **Introducció**
- **Riscos**
 - **Riscos ètics/socials**
 - **Riscos legals**
 - **Altres riscos**

Introducció

- L'ètica és una disciplina de la filosofia enfocada en determinar què és moralment bo o dolent o moralment correcte o incorrecte.
- En el cas de l'**ètica de la IA**, es debat sobre com maximitzar els beneficis per a les persones i la societat mentre es minimitzen els riscos i els impactes adversos ([AI ethics, defined - IBM](#)).
- La IA és una eina, no és "bona" ni "dolenta". Depèn de com la creem i com l'utilitzem.

**Anthropic amplia Project Glasswing:
quan la IA troba més vulnerabilitats
de les que podem corregir**

**Els models d'IA més potents d'OpenAI es
descontrolen i llancen un ciberatac "sense
precedents"**

Les proves que es feien amb GPT i un altre model encara no identificat en un entorn aïllat es van descontrolar quan van poder entrar a internet i atacar l'empresa d'IA Hugging Face

Introducció

4. The value consumers get from generative AI grew 54% in a year.

Estimated U.S. consumer surplus reached \$172 billion annually by early 2026, up from \$112 billion a year earlier, with the median value per user tripling over the same period. Most of these tools remain free or close to it.

L'impacte de la IA en el mercat laboral: 1 de cada 10 feines perillen en la pròxima dècada

El govern admet que la intel·ligència artificial està deixant sense feina algunes persones a Catalunya i es compromet a impulsar una transformació per adaptar-se a les noves dinàmiques

La IA al otro lado de los pupitres o cómo los profesores la usan para dar clase

- ▶ El profesorado muestra interés por la IA, pero aún no hay una estrategia definida por parte de la administración
- ▶ Plataformas como Edvolution han cambiado su enfoque, de la digitalización a enseñar IA al profesorado

ChatGPT afecta el cervell dels estudiants: què és el deute cognitiu?

Un estudi del MIT alerta que la IA fa més passius els estudiants i redueix la memòria i la creativitat

Study Suggests AI Is Good Enough at Diagnosing Complex Medical Cases To Warrant Clinical Testing

LLM outperformed physicians on clinical tasks spanning published cases, real-world emergency room data

← 16 dies de diferència →

AI fails at primary patient diagnosis more than 80% of the time, study finds

AI language models fail to produce an appropriate early diagnosis more than 80% of the time, suggesting they are not yet safe for unsupervised clinical use, according to a new study.

*LLMs

Introducció

- Hi ha organitzacions o governs que impulsen l'ètica de la IA.



Partnership on AI: és una organització sense ànim de lucre que reuneix experts (en IA i en drets humans) i empreses per establir polítiques de control i bones pràctiques.



EthicNet: busca crear un conjunt de dades etiquetat per humans que permeti entrenar models que prenguin consideracions ètiques.



Oficina d'IA de la UE: supervisa i fa complir les obligacions dels proveïdors de models d'IA de propòsit general.



Algorithmic Justice League: se centra a reduir els biaixos dels models assolint models més ètics i justos.



AI4People: és una organització europea que genera reports i informes sobre el desenvolupament de polítiques en l'àmbit de la IA.



AESIA (Agència Espanyola de Supervisió de la IA): és l'organisme públic encarregat de garantir l'ús ètic i segur de la IA a Espanya.

Riscos

- Per poder "*minimitzar els riscos i impactes adversos*" de la IA cal saber quins són.
 - Alguns són més fàcils d'evitar o minimitzar que altres.
 - La gravetat dels riscos també depenen del camp d'aplicació de la IA.
- Per organitzar-los, seguiré la següent classificació que és subjectiva. A més, hi ha elements que podrien estar en més d'un tipus:
 - Riscos ètics/socials: qüestions morals que afecten als individus o a la societat.
 - Riscos legals: incompliment de lleis (excepte lleis per regular la IA).
 - Altres riscos relatius a la fiabilitat/robustesa.
- A més, IBM té un [atles de riscos de la IA](#). Té una classificació diferent.

Riscos ètics/socials - Biaixos

- En IA, un **biaix** (sesgo en castellà, bias en anglès) és una **predisposició d'un sistema d'IA cap a determinats resultats a grups concrets**, que pot donar lloc a resultats distorsionats, inadequats o discriminatoris.
- Els biaixos en els models **poden afectar decisions que haurien de basar-se en criteris objectius** i provocar resultats discriminatoris o menys exactes per a determinats grups.
 - **Biaix en les dades**: les dades utilitzades no representen adequadament la realitat o contenen desequilibris.
 - **Biaix social**: el model aprèn i reproduïx prejudicis o estereotips presents en la societat.

Riscos ètics/socials - Biaixos

Exemples:

- Als EUA, l'ús del **codi postal en sistemes de concessió de crèdit pot introduir un biaix racial**. Com que el codi postal pot estar fortament relacionat amb la composició racial del barri, el model pot acabar penalitzant persones que viuen en determinades zones, encara que siguin bons pagadors.
- Els sistemes de classificació de gènere poden presentar biaixos quan les **dades d'entrenament no representen adequadament tots els grups**. En el cas de Gender Shades (2018), les dones negres presentaven les taxes d'error més elevades, de fins al 34,7%.
- BERT, desenvolupat per Google, és un dels primers models de llenguatge basats en Transformers, i **associa professions diferents segons el gènere**: per a man apareixen opcions com doctor o lawyer, mentre que per a woman apareixen nurse, waitress o maid.

Riscos ètics/socials - Biaixos

Causes:

- **Dades:** la manca de representativitat, els desequilibris o els biaixos presents en les dades poden reproduir-se en els resultats del sistema.
- **Mesurament i avaluació:** la selecció de les mètriques i dels processos de prova pot ocultar diferències de rendiment entre diferents grups.
- **Factors humans:** les decisions i els biaixos socials o històrics de les persones i organitzacions poden influir en el disseny i l'ús del sistema.
 - A l'exemple anterior, decidir utilitzar el codi postal com a variable del model és una decisió humana que va influir en el resultat.

Riscos ètics/socials - Biaixos

- **Detectar biaixos:** comparar els resultats del sistema entre diferents grups i analitzar les dades i variables utilitzades.

Al mòdul de Sistemes d'Aprenentatge Automàtic veureu diferents eines per avaluar els models, algunes de les quals també poden ajudar a detectar possibles biaixos.

- **Reduir biaixos:** millorar la representativitat de les dades, revisar les variables i el disseny del sistema i avaluar-ne el comportament abans i després de la implementació. A l'[article d'IBM](#) s'enumeren els passos per a reduir-los.

Riscos ètics/socials - Social scoring

- Són sistemes que **avaluen o classifiquen persones** a partir de les seves accions diàries, hàbits, comportament, personalitat, etc., i **utilitzen aquesta puntuació per determinar el tracte que rebran**.
- Aquest tipus de sistemes poden utilitzar **dades personals** per a finalitats diferents d'aquelles per a les quals es van obtenir, poden **discriminar** grups vulnerables o minories i poden **condicionar el comportament** de les persones.
 - En casos extrems, com els diferents sistemes de crèdit social que hi ha a la Xina, poden arribar a condicionar l'accés a serveis, oportunitats laborals o altres activitats, i limitar la llibertat d'actuació de les persones.

Riscos ètics/socials - Pèrdua de responsabilitat individual

- L'ús d'un sistema d'IA per prendre o recomanar decisions pot fer que les persones **deleguin part de la seva responsabilitat** en el sistema, especialment quan no entenen com s'ha arribat al resultat. No tenir clar de qui és la responsabilitat pot dificultar el compliment normatiu amb les regulacions.
- De qui és la responsabilitat si se segueixen les indicacions d'un sistema d'IA i hi ha víctimes? I al revés?
 - Exemple: Un metge segueix una recomanació d'un sistema d'IA que resulta incorrecta. De qui és la responsabilitat: del metge, del desenvolupador, de l'empresa que ha implantat el sistema o del propi sistema?
 - I si un sistema d'IA fa una recomanació correcta i el metge decideix ignorar-la? Pot ser responsable d'haver pres una decisió incorrecta?

Riscos ètics/socials - Mals usos

- Fer servir la IA amb la **intenció de fer mal a persones**.
 - Generar intencionadament informació falsa o desorientadora per enganyar o influir a la gent.
 - Imitar o fer-se passar per altres persones. *Deepfakes*.
 - Crear contingut tòxic o odiós.
- Utilitzar models que s'han fet per un propòsit per un de diferent.
- No indicar clarament quin contingut s'ha generat amb IA.

Riscos ètics/socials - Afectacions socials i econòmiques

- **Pèrdua de feina i d'oportunitats** ([Notícia](#)). L'automatització de treballs pot comportar l'eliminació de molts llocs de treball. Certs usos de la IA poden fer que hi hagi grups que perdin oportunitats.
- **Impacte negatiu a comunitats i a la [diversitat cultural](#)**. Els models que no són prou representatius poden ignorar context rellevant de certes comunitats o derivar en una homogeneïtzació de la cultura i pensament. Les dades sintètiques generades per IA poden ignorar poblacions marginals, pel que el que es faci a partir d'aquelles dades també ho farà.
- **Impacte negatiu en el [medi ambient](#)**. Els models d'IA poden incrementar les emissions de CO2 i el consum d'aigua.
- **Impacte negatiu en [educació](#)**. L'ús sense regulació per part d'alumnes de models d'IA pot comportar a que se saltin el procés d'aprenentatge.

Riscos legals - Privacitat

- La llei de protecció de dades dona uns **drets digitals** als ciutadans. Depenent de com s'entrenin o s'utilitzin sistemes d'IA, pot ser que es **vulnerin aquests drets**.
- Utilitzar dades personals (identificació o informació sensible) per a l'entrenament, fine-tuning, prompts, etc., pot comportar que aquestes dades apareguin als resultats d'un sistema d'IA. [Notícia](#).

Publiquen imatges enviades per usuaris a ChatGPT

En les últimes hores també s'ha sabut que agents d'OpenAI van publicar a internet **53 imatges** que havien estat enviades a ChatGPT per **usuaris particulars**.

Riscos legals - Drets d'autor / propietat intel·lectual

- Un model d'IA pot generar contingut que **infringeix drets d'autor** (copyright o altres llicències).
- El fàcil accés a models d'IA pot comportar que hi hagi **plagi** i no es doni el crèdit als autors originals.
- No està regulat **de qui és l'autoria de continguts generats per IA**. És de l'empresa que ha fet el model? És dels autors de les dades que s'han utilitzat per crear-lo? És de qui ha fet el *prompt*?

Altres riscos - Transparència en l'origen de les dades

- Els models d'IA haurien de tenir **documentat com s'han obtingut les dades, com s'han curat i com s'ha entrenat el model.**
- Si aquesta documentació no és completa **es dificulta la tasca d'avaluar els riscos associats amb les dades** i, per tant, detectar i reduir biaixos en el model.
- També, es dificulta detectar quan les dades no són fiables, s'han obtingut de manera poc ètica o s'han manipulat. Cal tenir en compte també la possibilitat de treballar amb **dades enverinades**.

Altres riscos - Explicabilitat (transparència del model)

- Els models basats en xarxes neuronals o la falta de transparència en les dades dificulten explicar els resultats.
- Això dificulta l'avaluació del models i fa més difícil entendre'ls confiar en ells.

Altres riscos - Resultats inesperats

- Un model pot generar consells incomplets per falta d'informació o al·lucinacions (informació incorrecta o inventada). En els dos casos, l'ús d'aquests continguts pot ser perjudicial.
- Els models poden causar prejudicis en la població o causar mal a les persones.
- En el cas de la generació de codi, poden incloure codi maliciós o vulnerabilitats.
- Els models poden saltar-se les restriccions que tenen per a limitar certes accions. Quan es fan proves, agents d'IA han realitzat atacs a sistemes informàtics fora del seu abast.



Crèdits: Adaptació dels materials de Francesc Barragan i anteriors professors del mòdul, amb llicència CC BY-SA. Revisat, ampliat i modificat per Miquel Floriach. Aquesta adaptació es distribueix sota la mateixa llicència.