

1.5. IA fiable i marc legal

M5071 - Models d'Intel·ligència Artificial
Miquel Floriach - mfloriach@sapalomera.cat



Índex

- **IA Fiable (Recomanacions)**
- **Marc legal**
 - **Regulació de la IA (UE i Espanya)**
 - **Protecció de dades (UE i Espanya)**

IA Fiable (Recomanacions)

- El 2019 es van presentar les [Directrius ètiques per una IA fiable](#). Una IA fiable ha de ser:
 - **Legal** – respecte a totes les disposicions legals i reglamentàries aplicables.
 - **Ètica** – respecte dels principis i valors ètics.
 - **Robusta** – des d'una perspectiva tècnica i tinguent en compte l'entorn social.
- No cal que només compleixi el marc legal, sinó que afegeix uns requisits addicionals. Aquests requisits s'han de treballar i avaluar constantment per totes les parts:
 - Els desenvolupadors de sistemes d'IA han d'introduir i aplicar els requisits.
 - Els responsables del desplegament en organitzacions han d'assegurar-se que els sistemes compleixen els requisits.
 - Els usuaris finals i la societat en el seu conjunt han de romandre informats sobre els requisits i tenir la capacitat de demanar que es compleixin.

IA Fiable - Requisits

Acció i supervisió humanes.

- Respectar els **drets fonamentals** de les persones. Minimitzar l'impacte negatiu sobre els aquests drets o valorar el balanç quan s'intenta protegir els drets i llibertats d'altres persones.
- **Acció humana.** Assegurar que els usuaris puguin prendre decisions autònomes amb coneixement de causa. Anar amb compte amb sistemes que manipulen el subconscient. Dret a no sotmetre als usuaris a conseqüències legals derivades exclusivament de processos automatitzats (*inclòs també a la llei de protecció de dades*).
- **Supervisió humana.** Incloure mecanismes de governança humana en sistemes d'IA, ja sigui:
 - Participació humana: capacitat d'intervenir en tots els cicles de decisió del sistema.
 - Control humà: capacitat d'intervenir durant el disseny del sistema i el seguiment del funcionament.
 - Mandat humà: capacitat de supervisar l'activitat global (efectes) i decidir com i quan utilitzar el sistema.
 - (Sempre) Supervisió per part de responsables públics.

IA Fiable - Requisits

Solidesa tècnica i seguretat

- **Relació amb el principi de prevenció del dany.** S'han de desenvolupar amb un enfocament preventiu en relació als riscos de manera que es minimitzin danys involuntaris i inesperats.
- **Resistència a atacs i seguretat.** Els sistemes d'IA s'han de protegir davant vulnerabilitats d'atacs, que poden dirigir-se a les dades (enverinament), el model (fallada) o a la infraestructura.
- **Pla de replegament i seguretat general.** Disposar de salvaguardes, per exemple que permetin passar a un model basat en normes o demanar intervenció d'un operador.
- **Precisió.** Utilitzar models amb alts nivells de precisió o que iniquin l'error.
- **Fiabilitat i reproductibilitat.** Els resultats dels sistemes han de ser iguals amb les mateixes condicions.

IA Fiable - Requisits

Privacitat i gestió de dades

- **Relació amb el principi de prevenció del dany.** Cal assegurar que els sistemes respectin la privacitat per evitar danyar el dret a la privacitat.
- **Protecció de la intimitat i les dades.** Garantir la protecció de la intimitat i les dades dels usuaris, ja siguin dades proporcionades pels usuaris, continguts generats pels usuari i informació inferida.
- **Qualitat i integritat de les dades.** Analitzar que les dades no tinguin biaixos ni siguin malicioses abans de ser utilitzades.
- **Accés a les dades.** Establir protocols que descriguin qui pot accedir a les dades i en quines circumstàncies.

IA Fiable - Requisits

Transparència

- **Relació amb el principi d'explicabilitat.**
- **Traçabilitat.** Documentar-ho tot seguint la norma més rigorosa.
- **Explicabilitat.** Les decisions que prengui han de ser comprensibles per humans. Pot ser necessari buscar un equilibri amb la precisió. Si pot haver un impacte significatiu en la vida d'una persona s'ha de poder explicar.
- **Comunicació.** Un sistema d'IA no es pot presentar com un humà, les persones tenen dret a saber que parlen amb una IA. S'ha de donar l'opció de parlar amb un humà en comptes d'un sistema d'IA. Segons el cas, cal comunicar informació sobre la precisió del sistema i les seves limitacions.

IA Fiable - Requisits

Diversitat, no discriminació i equitat

- **Necessitat d'evitar biaixos injustos.** Sempre que sigui possible, cal eliminar els biaixos identificables i discriminatorias en la fase de recopilació de dades. S'hauria de fomentar la contractació de persones de contextos diversos, cultures i disciplines per garantir la diversitat d'opinions.
- **Accessibilitat i disseny universal.** En l'àmbit de relacions entre empreses i consumidors, cal que els sistemes es puguin utilitzar amb independència d'edat, gènere, capacitats o característiques (especialment per a persones amb discapacitat). Cal tenir en compte els [principis del Disseny Universal](#).
- **Participació de les parts interessades.** Cal consultar a les parts interessades que es puguin veure afectades pel sistema d'IA, durant el disseny i durant el seu cicle de vida.

IA Fiable - Requisits

Benestar social i mediambiental

- **IA sostenible i respectuosa amb el medi ambient.** Garantir el màxim respecte pel medi ambient del sistema d'IA i la seva cadena de subministrament durant el desenvolupament i cicle de vida. Cal donar prioritat a les opcions menys perjudicials.
- **Impacte social.** Cal fer un seguiment de l'impacte dels sistemes d'IA sobre el benestar físic i mental de les persones.
- **Societat i democràcia.** Cal avaluar els efectes sobre les institucions, la democràcia i la societat en el seu conjunt. Cal ser exhaustius, sobretot en situacions relacionades la presa de decisions polítiques i contextos electorals.


IA Fiable - Requisits

Rendiment de comptes

- **Auditabilitat.** El sistemes (dades, algorismes i disseny) s'han de poder avaluar. En el cas que els sistemes puguin afectar a drets fonamentals cal que es facin auditories independents.
- **Minimització d'efectes negatius i notificació d'aquests.** Cal garantir que es pugui informar sobre les decisions i els efectes de sistemes d'IA. Cal protegir a qui traslladi preocupacions legítimes sobre els sistemes.
- **Cerca d'equilibris.** Cal trobar equilibris en l'aplicació de tots els requisits. Han d'estar documentats i justificats.
- **Compensacions.** Ha d'haver mecanismes accessibles per assegurar compensacions adequades en cas d'efectes adversos.

Marc legal - Regulació de la IA

- Regulació de 2024, modificada el 2026.
- [Web divulgativa](#). [Explorador del AI Act](#).
- Estableix normes basades en el **risc** dels sistemes d'IA.
- Es defineixen 4 nivells de risc.



Marc legal - Regulació de la IA

1. Risc inacceptable. Es consideren una clara amenaça i estan **prohibits**. Són:

- Manipulació i engany perjudicials basats en IA (també subliminal).
- Explotació nociva de vulnerabilitats de persones basada en IA.
- Puntuació social (social scoring) en casos concrets.
- Avaluació o predicció del risc d'infracció penal per part de persones concretes utilitzant informació que no siguin fets objectius.
- *Scrapping* indiscriminat d'Internet o CCTV per a crear bases de dades de reconeixement facial.
- Reconeixement d'emocions en llocs de treball o institucions educatives.
- Categorització biomètrica per deduir determinades característiques protegides.
- Identificació biomètrica remota en temps real amb finalitats policials en espais d'accés públic.
- Sistemes d'IA que generen contingut sexualment explícit i íntim no consentit o material d'abús sexual a menors, com aplicacions de "nudificació". (*Nova, desembre 2026*)

*Cal revisar el que hi ha escrit a la llei, ja que hi ha matisos i excepcions.

Marc legal - Regulació de la IA

2. Alt risc. Poden plantejar riscos greus per la salut, la seguretat o drets fonamental. **Són:**

- Components de seguretat d'IA en infraestructures crítiques.
- Solucions d'IA utilitzades en institucions educatives que poden determinar l'accés a la educació i el curs de la vida professional d'una persona.
- Components de seguretat basats en IA.
- Eines d'IA per al treball, gestió de treballadors i accés al treball a compte propi.
- Casos d'ús d'IA utilitzats per a donar accés a serveis essencials (públics i privats).
- Sistemes d'IA utilitzats per la identificació biomètrica remota, reconeixement d'emocions i categorització biomètrica (no indiscriminat → inacceptable).
- Ús d'IA en forces i cossos de seguretat que poden interferir en els drets fonamentals de les persones.
- Ús d'IA en la gestió de migració, asil i control fronterer.
- Solucions d'IA utilitzades en l'administració de la justícia i processos democràtics.

Marc legal - Regulació de la IA

2. Alt risc. Poden plantejar riscos greus per la salut, la seguretat o drets fonamental. **Obligacions** (a partir del 2 de desembre de 2027):

- Sistemes adequats d'avaluació i mitigació de riscos.
- Alta qualitat de les dades que alimenten el sistema per minimitzar el risc de discriminar.
- Registre d'activitat per a la traçabilitat.
- Documentació detallada amb tota la informació necessària sobre el sistema i la seva finalitat.
- Informació clara i adequada a l'implementador.
- Mesures adequades de supervisió humana.
- Alt nivell de robustesa, ciberseguretat i precisió.

*Molt similar a algunes recomanacions d'una IA fiable.

Marc legal - Regulació de la IA

2. Alt risc. Poden plantejar riscos greus per la salut, la seguretat o drets fonamental.



Marc legal - Regulació de la IA

3. Risc de transparència. Aplica quan hi ha riscos associats a la transparència (comunicació).

Obligacions (a partir de l'agost de 2026):

- Informar quan s'interacciona directament amb un sistema d'IA quan no és clar.
- (Proveïdors) Garantir que els continguts generats per IA siguin identificables.
- Informar del funcionament de sistemes de reconeixement d'emocions o de categorització biomètrica.
- Identificar clarament quan certs continguts s'han generat o modificat amb IA:
 - *Deepfakes.*
 - Text publicat amb la finalitat d'informar al públic sobre assumptes d'interès públic.

Marc legal - Regulació de la IA

4. Risc mínim o sense risc.

Exemples:

- IA en videojocs.
- Spam filters.

No s'inclou cap normativa en aquests casos.

Marc legal - Projecte de Llei orgànica per al bon ús i la governança de la intel·ligència artificial

(Probablement decaigui per l'avançament electoral)

- Implementa la llei europea.
- Incorpora mesures per fomentar que el sector públic adopti la IA.
- Nous sistemes prohibits (inacceptables) - Incorporats a la llei europea amb la modificació del 2026:
 - *Deepfakes* sexuals.

Marc legal - Protecció de dades

L'objectiu és garantir i protegir la privacitat i la intimitat de les persones físiques.

- **Drets dels ciutadans.**

- Dret d'accés. Facilitar accés remot, directe i segur a les dades personals.
- Dret de rectificació. Rectificació de les dades personals inexactes.
- Dret de supressió (dret a l'oblit). Supressió de les dades personals en determinats casos.
- Dret a la limitació del tractament. Limitació de l'ús posterior en determinats casos.
- Dret a la portabilitat de les dades. L'interessat té dret a rebre les seves dades personals i transmetre-les a un altre responsable.
- Dret d'oposició. Oposar-se a l'ús de les dades en certs casos.

- **Responsabilitat proactiva.** S'obliga a les empreses i administracions a aplicar mesures tècniques i organitzatives per garantir i poder demostrar que el tractament de les dades és segur i legal.

Marc legal - Llei orgànica 3/2018, de 5 de desembre, de protecció de dades personals i garantia dels drets digitals

- Implementa la llei europea.
- L'edat mínima per al consentiment del tractament de dades és de 14 anys.
- Afegeix un capítol de garantia dels drets digitals (títol x).



Crèdits: Adaptació dels materials de Francesc Barragan i anteriors professors del mòdul, amb llicència CC BY-SA. Revisat, ampliat i modificat per Miquel Floriach. Aquesta adaptació es distribueix sota la mateixa llicència.