


Arquitectures Big Data

Blocs 1 i 2 · Arquitectures + Batch i Streaming



Objectiu: entendre com es dissenya el sistema abans d'escollir les eines.

1. El problema: moltes dades no són només “més dades”

Cas inicial: 100.000 sensors

$$100.000 \text{ sensors} \times 1 \text{ dada / segon} = 100.000 \text{ esdeveniments / segon}$$

Preguntes

On les guardem?
Com arriben?
Com les processem?
Què passa si falla un servidor?

Pregunta clau

Quina informació volem obtenir i quina decisió volem poder prendre?

2. Què és una arquitectura Big Data?

Dissenyem el sistema abans d'escollir les eines

Una arquitectura Big Data permet gestionar la ingesta, el processament i l'anàlisi de dades massa grans o complexes per a un sistema tradicional.

INGESTA

Com entren les dades?

PROCESSAMENT

Com les transformem?

ANÀLISI

Com obtenim informació?

No és una tecnologia concreta: és una manera d'organitzar components i fluxos.

3. Característiques d'una arquitectura Big Data

Cinc idees que han de guiar el disseny

Escalabilitat

Augmentar fàcilment capacitat.

Tolerància a fallades

Continuar funcionant encara que fallin màquines.

Dades distribuïdes

Evitar un únic node central.

Processament distribuït

Repartir el tractament entre màquines.

Localitat de la dada

Apropar dades i processos.

4. Escalar: fer més gran o afegir màquines?

Escalat vertical i horitzontal

Escalat vertical



Escalat horitzontal



Però distribuir també introdueix coordinació, xarxa, fallades i repartiment de dades i feina.

5. Per què distribuïm les dades i el processament?

Bloc 1

Repartim dades i feina



Avantatge

Repartir càrrega i créixer afegint recursos.

Cost

La xarxa i la coordinació passen a formar part del problema.

Objectiu

Evitar moviments innecessaris de dades.

6. Localitat de la dada

Moure dades per la xarxa té un cost



Més trànsit → més latència → més temps d'execució

Principi: quan sigui possible, apropem el processament a les dades.

7. Abans d'escollir tecnologia: quin problema tenim?

Els requisits guien l'arquitectura

Volum

Quantes dades?

Velocitat

A quina velocitat arriben?

Temps de resposta

Quan necessitem el resultat?

Fiabilitat

Què passa si falla?

Evolució

Com canviarà el sistema?

Regla d'or: evitar la sobreenginyeria.

8. Quan processem les dades?

Dues formes bàsiques de tractament

BATCH

Processar un conjunt de dades amb inici i final temporal.

STREAMING

Processar nova informació a mesura que arriba, sense un final temporal.

La decisió depèn del problema i del temps de resposta.

No tot és temps real.

9. Processament Batch

Treballar amb lots de dades



Exemple

Total de vendes del dia calculat cada nit.

Quan encaixa?

Quan podem esperar i volem treballar amb un conjunt complet.

Idea clau

El procés té inici i final temporal.

10. Processament en Streaming

Tractar les dades mentre van arribant



→ → → els esdeveniments continuen arribant → → →

Exemple

Un sensor envia temperatura cada segon i volem detectar una situació anòmla.

Avantatge

Podem obtenir resultats amb baixa latència.

Però...

Streaming no significa resposta instantània ni que sempre el necessitem.

11. Batch vs Streaming

Comparar abans d'escollir

Aspecte	Batch	Streaming
Entrada	Conjunt de dades	Flux continu
Temps	Inici i final	Sense final temporal
Resposta	Pot tenir més latència	Baixa latència
Ús típic	Informes i càlculs històrics	Esdeveniments i anomalies

Pregunta: hi ha casos en què necessitem combinar les dues aproximacions?

12. Activitat: Batch o Streaming?

Decidiu i, sobretot, justifiqueu

CAS

1. Informe mensual de vendes.

CAS

2. Detectar una temperatura perillosa.

CAS

3. Recalcular cada nit l'històric.

CAS

4. Detectar una transacció sospitosa mentre es produeix.

CAS

5. Calcular les notes finals d'un curs.

CAS

6. Mostrar els usuaris connectats ara.

No busquem només la resposta: expliqueu quin requisit us ha fet decidir.

13. El problema que ens porta a Lambda

Precisió històrica + resposta ràpida

MATEIXES DADES

DADES

BATCH

Tot l'històric.
Més precisió, però més latència.

STREAMING

Dades recents.
Resposta ràpida, però només cobreix
l'última part del flux.

I si l'aplicació necessita les dues coses?

14. Resum dels blocs 1 i 2

Abans d'entrar a Lambda

- Una arquitectura Big Data organitza els components per gestionar dades a gran escala.
- Escalabilitat, tolerància a fallades, distribució i localitat són principis fonamentals.
- Batch treballa amb lots: té inici i final temporal.
- Streaming processa nova informació a mesura que arriba.
- No tot necessita temps real: el requisit de negoci marca l'arquitectura.
- Quan volem combinar l'històric precís i les dades recents apareix el problema de Lambda.

PROPER PAS → ARQUITECTURA LAMBDA