

Kappa + Delta

De l'únic camí de processament al Lakehouse.

→ **KAPPA**

Un flux

▣ **DELTA LAKE**

Dades + ACID

◆ **LAKEHOUSE**

Un entorn analític

La pregunta que deixa Lambda sobre la taula

λ LAMBDA

Batch + Streaming


Dos camins
Possible duplicació de lògica
Més complexitat

κ KAPPA

I si tot fos un stream?


Un únic camí
Una lògica
Reprocessament

Un únic camí



Mateix camí per dades noves i reproprocessament

Un únic camí



Mateix camí per dades noves i reproprocessament

Els 4 pilars

01 Tot és un stream:
les operacions *batch* són un subconjunt de les operacions de *streaming*, per la qual cosa tot pot ser tractat com un *stream*.


02 Dades immutables:
les dades s'emmagatzemen sense ser transformades, per tant, són immutables, i les vistes se'n deriven. Un estat concret pot ser recalculat atès que la informació d'origen no es modifica.

03 Un únic flux

04 Reprocessament:
es pot modificar un processament concret i la seva configuració per variar els resultats obtinguts partint de les mateixes dades d'entrada

No cal memoritzar la frase: cal entendre què implica.

Les dades d'origen no es toquen



Mateixes dades d'entrada · processament diferent · resultat diferent

Com a requisit previ a complir, s'ha de garantir que els esdeveniments es llegeixen i emmagatzemen en l'ordre en què s'han generat.


D'aquesta manera, podem variar un processament concret partint d'una mateixa versió de les dades.

Kafka encaixa amb la idea de log d'esdeveniments



Per reprocessar cal disposar dels esdeveniments necessaris


Kafka encaixa amb la idea de log d'esdeveniments



Per reprocessar cal disposar dels esdeveniments necessaris

Reprocessar és tornar a llegir l'origen

AVUI



La dada d'origen continua sent la mateixa.

Lambda i Kappa: dues maneres de plantejar el processament

λ LAMBDA

2 camins

Batch → històric

Streaming → baixa latència

Flexibilitat, però més complexitat

κ KAPPA

1 camí

Streaming → dades noves +
reprocessament

Menys duplicació, però depèn de poder
conservar/reproduir el flux

Ara canviem el focus: com gestionem les dades?

KAPPA
processament

▣ DELTA LAKE

Tecnologia d'emmagatzematge

ACID · metadades · esquemes
Integració amb Spark i Structured
Streaming

LAKEHOUSE

Important: Delta Lake ≠ automàticament Delta Architecture

Data Lake + capacitats de gestió



Idea: no és només guardar fitxers; també gestionem l'estat de les dades.

Què aporta?

A Atomicitat

L'operació és indivisible

C Consistència

Es preserven les regles

I Aïllament


Les operacions no interfereixen indegudament

D Durabilitat

El resultat persisteix

El document també destaca metadades, esquemes i integració amb Spark.

Bronze → Silver → Gold



Quin problema intenta reduir?

! ENFOCAMENT COMPLEX

- Més còpies
- Més salts de dades
- Més gestió de coherència
- Més components

✓ ENFOCAMENT LAKEHOUSE

- Una plataforma de dades
- Transaccions
- Refinament Bronze/Silver/Gold
- Menys salts

No resolen exactament el mateix problema

LAMBDA

Dos camins
Batch + Streaming

KAPPA

Un camí
Streaming + replay

DELTA / LAKEHOUSE

Gestió de dades
ACID + capes

La pregunta sempre és: quin problema tenim?

Tria l'enfocament i justifica'l

01 Històric complet + resposta ràpida

?

02 Mateixa lògica + reprocessament

?

03 Data Lake + ACID + Bronze/Silver/Gold

?

No busquem memoritzar: busquem justificar.